



Telco Customer Churn Classification Prediction

Use Case:
Customer Churn or Not

Samuel Nathanael Sitompul

Outline

Overview Proyek

01.

03.

Hasil

Metodologi


02.

04.

Kesimpulan



Overview Proyek



Analisis Perilaku Churn Pelanggan

Menganalisis faktor yang menyebabkan pelanggan berhenti berlangganan.



Identifikasi Faktor Risiko Utama

Mengidentifikasi variabel utama seperti kontrak, tenure, dan tagihan.



Strategi Retensi

Hasil klasifikasi membantu perusahaan menyusun program retensi yang lebih tepat sasaran



Dataset

Berisi 7.043 pelanggan dan 21 fitur dengan Churn sebagai target.

Deskripsi Data & Variabel Kunci

Variabel Dependen (Target)

Model memprediksi status Churn, yaitu pelanggan berhenti berlangganan (1) atau tetap berlangganan (0).

Variabel Independen Utama (Fitur)

- Demografi: Gender, Senior Citizen, Partner, Dependents.
- Layanan: Phone, Internet, Streaming, Security, dan layanan tambahan lainnya.
- Akun Pelanggan: Tenure, jenis kontrak, metode pembayaran, tagihan bulanan & total.
- Perilaku Pembayaran: Paperless billing dan pola biaya langganan.





METODOLOGI

- Analisis klasifikasi dilakukan menggunakan dua algoritma utama yaitu Logistic Regression (sebagai model linear baseline) dan Random Forest (sebagai model ensemble non-linear).
 - Dilakukan analisis distribusi variabel target (Churn) serta hubungan antara fitur numerik dan kategorikal terhadap risiko churn untuk menemukan pola awal dalam data.
 - Meliputi pembersihan data, penanganan missing value, encoding variabel kategorikal (binary mapping & One Hot Encoding), serta normalisasi fitur numerik menggunakan StandardScaler.
 - Model dievaluasi menggunakan Cross-Validation dengan metrik utama Accuracy, Precision, Recall, F1-Score, dan ROC-AUC untuk memastikan performa yang seimbang dan konsisten.
- 
- 
- 

METODOLOGI

Dataset

Dataset yang digunakan dalam proyek ini adalah data Telkom Customer Churn yang berisi informasi pelanggan layanan telekomunikasi. Dataset terdiri dari 7.043 baris (pelanggan) dan 21 kolom (fitur) yang mencakup data demografi, layanan yang digunakan, serta informasi akun pelanggan.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 7043 entries, 0 to 7042
Data columns (total 21 columns):
#   Column                Non-Null Count  Dtype
---  -
0   customerID            7043 non-null   object
1   gender                 7043 non-null   object
2   SeniorCitizen          7043 non-null   int64
3   Partner                7043 non-null   object
4   Dependents             7043 non-null   object
5   tenure                 7043 non-null   int64
6   PhoneService           7043 non-null   object
7   MultipleLines           7043 non-null   object
8   InternetService        7043 non-null   object
9   OnlineSecurity         7043 non-null   object
10  OnlineBackup           7043 non-null   object
11  DeviceProtection       7043 non-null   object
12  TechSupport            7043 non-null   object
13  StreamingTV            7043 non-null   object
14  StreamingMovies        7043 non-null   object
15  Contract               7043 non-null   object
16  PaperlessBilling       7043 non-null   object
17  PaymentMethod          7043 non-null   object
18  MonthlyCharges         7043 non-null   float64
19  TotalCharges           7043 non-null   object
20  Churn                  7043 non-null   object
dtypes: float64(1), int64(2), object(18)
memory usage: 1.1+ MB
```

Data Preprocessing

Mengganti Tipe Data

```
df['TotalCharges'] = pd.to_numeric(df['TotalCharges'], errors='coerce')
```



```
df.info()
```

Data Preprocessing

Missing Value

Data yang bernilai null hanya berjumlah 11 jadi bisa dihapus

```
df = df.dropna()
```

```
df.isnull().sum()
```

0

customerID 0

gender 0

Outlier

```
numerical_columns = Index(['SeniorCitizen', 'tenure', 'MonthlyCharges', 'TotalCharges'], dtype='object')
```

```
for col in numerical_columns:
    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)
    IQR = Q3 - Q1

    outliers = df[(df[col] < Q1 - 1.5*IQR) | (df[col] > Q3 + 1.5*IQR)]
    print(f"{col} jumlah outlier: {len(outliers)}")
```

```
SeniorCitizen jumlah outlier: 1142
tenure jumlah outlier: 0
MonthlyCharges jumlah outlier: 0
TotalCharges jumlah outlier: 0
```

Senior Citizen tidak perlu untuk dihapus karena fitur itu masuk ke dalam bentuk kategori


Duplicated Data

```
df.duplicated().sum()
```

```
np.int64(0)
```

Distribusi Kolom Preferensi (Target)


<Axes: xlabel='Churn', ylabel='count'>



Berdasarkan hasil distribusi kolom preferensi (target) terjadi imbalanced data, dimana preferensi No (Not Churn) itu lebih banyak dibandingkan preferensi Yes (Churn).


Maka dari itu perlu adanya parameter `class_weight = balance` dalam modelling dan beberapa metric tambahan seperti ROC-AUC untuk meningkatkan performa machine learning.

Heatmap Correlation




Berdasarkan hasil heatmap korelasi, fitur SeniorCitizen, tenure, dan MonthlyCharges menunjukkan hubungan yang sangat lemah satu sama lain, sehingga risiko multikolinearitas rendah dan data cenderung independen untuk pemodelan.

Analisis Fitur Kategorikal




Faktor utama churn terlihat dari besarnya selisih proporsi pada pelanggan tanpa pasangan, tanpa tanggungan, tanpa keamanan online, serta pengguna fiber optic, yang menunjukkan kelompok tersebut lebih rentan berhenti berlangganan. Sebaliknya, fitur gender dan layanan telepon memiliki selisih yang sangat kecil sehingga pengaruhnya terhadap churn masih tergolong ambigu.

Analisis Fitur Kategorikal



Besarnya selisih proporsi churn pada kontrak Month-to-Month dan ketiadaan layanan proteksi (Online Backup, Device Protection, Tech Support) menunjukkan bahwa kontrak jangka panjang serta bundling layanan tambahan merupakan faktor utama loyalitas pelanggan. Sementara itu, fitur streaming memiliki pengaruh yang lebih kecil karena selisihnya tidak setajam fitur kontrak dan layanan proteksi tersebut.

Analisis Fitur Numerik



Selisih signifikan pada rata-rata tenure dan Monthly Charges menunjukkan bahwa pelanggan baru dengan tagihan tinggi jauh lebih rentan untuk churn dibandingkan pelanggan lama. Hal ini mengindikasikan bahwa harga yang mahal di bulan-bulan awal berlangganan sering kali dirasakan tidak sebanding dengan nilai layanan, sehingga memicu pelanggan untuk segera berpindah ke kompetitor.

MODEL PREPARATION

Feature
Engineering

01

SPLIT
TRAIN-TEST

02

Encoding

03

Scaling

04

Feature Engineering

Charge Ratio

```
df['charge_ratio'] = df['MonthlyCharges'] / (df['TotalCharges'] + 1)
```

Mengukur rasio pembayaran bulanan terhadap total histori pembayaran

Feature Engineering

Tenure Group

```
df['tenure_group'] = pd.cut(df['tenure'],  
                             bins=[0,12,24,60,72],  
                             labels=['<1yr', '1-2yr', '2-5yr', '5yr+'])
```

Menggabungkan nilai yang sama untuk memudahkan dalam menangkap pola nonlinear

Split Test & Train Data

```
X = df.drop('Churn', axis=1)
y = df['Churn']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y)
```

Menentukan variabel independen (X) sebagai fitur dan variabel dependen (Y) sebagai target, kemudian melakukan pembagian dataset dengan rasio 80:20 untuk data train dan data test.

Encoding

```
y_train = y_train.map({'Yes':1,'No':0})
y_test = y_test.map({'Yes':1,'No':0})

binary_cols = ['gender','Partner','Dependents',
               'PhoneService','PaperlessBilling']

for col in binary_cols:
    X_train[col] = X_train[col].map({'Yes':1,'No':0,'Male':1,'Female':0})
    X_test[col] = X_test[col].map({'Yes':1,'No':0,'Male':1,'Female':0})

service_cols = ['OnlineSecurity','OnlineBackup','DeviceProtection',
               'TechSupport','StreamingTV','StreamingMovies','MultipleLines']

for col in service_cols:
    X_train[col] = X_train[col].replace({'No internet service':'No',
                                         'No phone service':'No'})
    X_test[col] = X_test[col].replace({'No internet service':'No',
                                       'No phone service':'No'})

    X_train[col] = X_train[col].map({'Yes':1,'No':0})
    X_test[col] = X_test[col].map({'Yes':1,'No':0})
```

```
contract_map = {
    'Month-to-month':0,
    'One year':1,
    'Two year':2
}

X_train['Contract'] = X_train['Contract'].map(contract_map)
X_test['Contract'] = X_test['Contract'].map(contract_map)

X_train = pd.get_dummies(X_train, columns=['InternetService','PaymentMethod', 'tenure_group'], drop_first=True)
X_test = pd.get_dummies(X_test, columns=['InternetService','PaymentMethod', 'tenure_group'], drop_first=True)

X_train, X_test = X_train.align(X_test, join='left', axis=1, fill_value=0)
```

Melakukan encoding dengan mengubah data kategorikal menjadi numerik (Yes/No dan Male/Female menjadi 1/0), mengubah Contract ke bentuk ordinal, serta menerapkan one-hot encoding. Kemudian menyamakan kolom X_train dan X_test agar konsisten.

Scaling

```
feature_names = X_train.columns  
scaler = StandardScaler()  
  
X_train = scaler.fit_transform(X_train)  
X_test = scaler.transform(X_test)
```

Melakukan proses scaling menggunakan StandardScaler untuk menstandarisasi fitur agar memiliki skala yang sama. Scaling dilakukan dengan fit pada data train dan transform pada data test untuk menghindari data leakage.

MACHINE LEARNING



LOGISTIC REGRESSION

```
... Fitting 5 folds for each of 20 candidates, totalling 100 fits
Best Parameters:
{'C': 0.001, 'class_weight': 'balanced', 'penalty': 'l2', 'solver': 'liblinear'}
```

Classification Report:

	precision	recall	f1-score	support
0	0.91	0.66	0.76	1033
1	0.47	0.83	0.60	374
accuracy			0.70	1407
macro avg	0.69	0.74	0.68	1407
weighted avg	0.79	0.70	0.72	1407

Confusion Matrix:

```
[[678 355]
 [ 65 309]]
```

True Negatives (TN): 678
False Positives (FP): 355
False Negatives (FN): 65
True Positives (TP): 309

SUMMARY METRICS

Accuracy : 0.7015 (70.15%)
Precision: 0.4654
Recall : 0.8262
F1-Score : 0.5954
ROC AUC : 0.8422

Hasil machine learning:

1. Rata-rata akurasi: 0.7015
2. Nilai ROC AUC: 0.8422
3. False Positive: 355 dan False Negative: 65

Maka berdasarkan hal ini model Logistic Regression memiliki performa yang cukup baik dalam mendeteksi churn (Recall 0.82), namun masih sering mengalami kesalahan prediksi pada kelas 0 yang menyebabkan tingginya angka False Positive.



MACHINE LEARNING

RANDOM FOREST CLASSIFIER

```
Fitting 3 folds for each of 6 candidates, totalling 18 fits
Best Parameters: {'criterion': 'gini', 'max_depth': 6, 'max_features': 'sqrt', 'n_estimators': 300}
*** Best CV F1 Score: 0.7926629698486666

Classification Report:
      precision    recall  f1-score   support

     0       0.91      0.72      0.81      1033
     1       0.51      0.80      0.62       374

 accuracy: 0.74      1407
 macro avg: 0.71      1407
 weighted avg: 0.80      1407

Confusion Matrix:
[[747 286]
 [ 75 299]]

 True Negatives (TN): 747
 False Positives (FP): 286
 False Negatives (FN): 75
 True Positives (TP): 299

=====
SUMMARY METRICS (RANDOM FOREST)
=====
Accuracy : 0.7434 (74.34%)
Precision: 0.5111
Recall : 0.7995
F1-Score : 0.6236
ROC AUC : 0.8409
```

Hasil machine learning :


1. Nilai akurasi : 0.7434
2. Nilai ROC AUC: 0.8409
3. False Positive : 286 dan False Negative : 75

Maka berdasarkan hal ini model Random Forest Classifier memiliki performa yang cukup solid dengan nilai recall yang tinggi (0.7995), namun model masih sering keliru dalam memprediksi kelas 0 yang menyebabkan tingginya angka False Positive.

Result

Random Forest dipilih sebagai model final karena memberikan keseimbangan performa yang lebih optimal melalui nilai akurasi, precision, dan F1-Score yang lebih tinggi. Meski Logistic Regression unggul tipis pada recall, keunggulan F1-Score Random Forest memastikan minimalisasi kesalahan prediksi (False Positive) yang lebih baik untuk efisiensi strategi retensi pelanggan.

FEATURE IMPORTANCE (RANDOM FOREST)



Fitur yang sangat berpengaruh:

- Contract (khususnya Month-to-Month) serta Tenure.
- Hal ini menjadi faktor dominan yang menentukan apakah pelanggan akan

Fitur yang berpengaruh:

- Internet Service (Fiber Optic) dan Monthly Charges.
- Fitur ini berkontribusi meningkatkan risiko churn, terutama pada pelanggan dengan tagihan tinggi yang merasa nilai layanan tidak sebanding.

Fitur yang berpengaruh kecil:

- Payment Method (Electronic Check) dan Layanan Tambahan (Online Security, Tech Support).
- Fitur ini menunjukkan pola churn tertentu namun pengaruhnya tidak sekuat faktor kontrak dan loyalitas waktu.

Kesimpulan

- Jenis Kontrak. Program insentif untuk mendorong pelanggan beralih dari Month-to-Month ke kontrak tahunan adalah intervensi paling berdampak.
- Tenure Rendah. Pelanggan di bawah 12 bulan pertama adalah kelompok paling rentan. Program onboarding dan engagement intensif di fase ini sangat direkomendasikan.
- Tagihan Tinggi tanpa Layanan Tambahan. Pelanggan dengan tagihan besar (terutama Fiber Optic) namun tidak berlangganan layanan proteksi atau dukungan teknis perlu ditawarkan bundling paket yang lebih komprehensif dan juga dapat meningkatkan performa dan pelayanan dari produk Fiber Optic itu sendiri.

Link Project:

Link colab :

https://colab.research.google.com/drive/1bZSVBwDqtHNKCXcWWkAtlKhPqyPaJt_M?usp=sharing



Thank You

